


YAPAY ZEKA TABANLI AKILLI ARAÇ GÖZETİM, SINIFLANDIRMA VE TAKİP SİSTEMİ: ÖZEL MODEL EĞİTİMİ VE ALGORİTMA KARŞILAŞTIRMA RAPORU

1. Proje Özeti ve Amacı

Günümüzde akıllı şehir konseptlerinin en önemli bileşenlerinden biri otonom trafik yönetimi ve denetimidir. Bu proje, şehir içi ve şehirler arası yollardaki araç trafiğini insan müdahalesi olmadan analiz etmek, araçları türlerine göre (Araba, Motosiklet, Otobüs, Kamyonet/Kamyon) sınıflandırmak ve anlık trafik yoğunluğunu ölçmek amacıyla geliştirilmiştir. Hazır (pre-trained) modellerin Türkiye'deki trafik kamera açılarına ve araç tiplerine uyum sağlamada yaşadığı zorluklar göz önüne alınarak, bu projede amaca özel bir veri seti oluşturulmuş ve özelleştirilmiş bir YOLO derin öğrenme modeli eğitilmiştir. Sistem; web tabanlı modüler bir mimari üzerinde birden fazla tespit (detection) modeli ve takip (tracking) algoritmasını eşzamanlı çalıştırabilen uç bilişim (edge computing) destekli bir yapı sunmaktadır.



```
169 def generate_frames():
170     except Exception as e:
171         print(f"[HATA] Beklenmeyen hata oluştu, kare atlıyor: {e}")
172         continue
173
174 # -----
175 # Flask arayüz
176 # -----
177 @app.route('/')
178 def index():
179     with config_lock:
180         det_t = DETECTOR_TYPE
181         trk_t = TRACKER_TYPE
182         dst_t = DISTANCE_TYPE
183
184     logs = db.get_latest_logs(10)
185     return render_template('index.html', logs=logs, detector_type=det_t, tracker_type=trk_t, distance_type=dst_t)
186
187 @app.route('/update_config', methods=['POST'])
188 def update_config():
189     global DETECTOR_TYPE, TRACKER_TYPE, DISTANCE_TYPE, MAX_WIDTH, MAX_HEIGHT
190     global trackable_objects, motion_history, ct, heatmap, total_cars_counted, class_counts
191     global correct_preds, wrong_preds, last_result_text, last_result_color, smoothed_accuracy
192
193     with config_lock:
194         DETECTOR_TYPE = request.form.get('detector')
195         TRACKER_TYPE = request.form.get('tracker')
196         DISTANCE_TYPE = request.form.get('distance')
197         MAX_WIDTH, MAX_HEIGHT = load_models()
198
199     total_cars_counted = 0
200     class_counts = {"Araba": 0, "Motosiklet": 0, "Otobüs": 0, "Kamyonet": 0}
201
202     correct_preds = 0
203     wrong_preds = 0
204     smoothed_accuracy = 0.0
205     last_result_text = "Araç Geçisi Bekleniyor..."
206     last_result_color = (0, 255, 255)
207
208     trackable_objects.clear()
209     motion_history.clear()
210     ct = CentroidTracker(max_disappeared=50, max_distance=60)
211     heatmap.reset()
212
213     return redirect(url_for('index'))
214
215 @app.route('/video_feed')
216 def video_feed():
217     return Response(generate_frames(), mimetype='multipart/x-mixed-replace; boundary=frame')
```

2. Veri Seti Mimarisi ve Ön İşleme

Özel modelin eğitimi için yüksek hacimli ve çeşitli trafik senaryolarını barındıran kapsamlı bir veri seti kullanılmıştır.

- **Sınıf Dağılımı:** Veri seti toplam 4 sınıftan oluşmaktadır: cars (Araba), motorcycle (Motosiklet), bus (Otobüs) ve truck (Kamyon).
- **Veri Hacmi:** Veri seti toplam 39.050 görüntüden oluşmaktadır. Eğitim (Train) aşaması için 31.240 görüntü, doğrulama (Validation) aşaması için 7.810 görüntü ayrılarak ağı daha önce görmediği verilerle test edilmesi sağlanmıştır.
- **Sınıf Dengesi:** Eğitim verilerindeki sınıf dağılımı %34.8 Araba (20.548 etiket), %29.0 Motosiklet (17.125 etiket), %18.9 Otobüs (11.170 etiket) ve %17.3 Kamyon (10.205 etiket) olarak homojen bir yapıya oturtulmuştur.
- **Veri Artırma (Data Augmentation):** Veri seti üzerinde aşırı öğrenmeyi (overfitting) engellemek amacıyla albumentations kütüphanesi ile *Blur*, *MedianBlur*, *ToGray* ve *CLAHE* (Kontrast Sınırlandırılmalı Adaptif Histogram Eşitleme) gibi teknikler uygulanarak kameranın farklı hava ve ışık koşullarına olan direnci artırılmıştır.

=====

DATASET DERİNLEMESİNE KONTROL

=====

✓ Sınıf sayısı: 4, Sınıflar: {0: 'cars', 1: 'motorcycle', 2: 'bus', 3: 'truck'}
Train img: 31240, lbl: 31240
Val img: 7810, lbl: 7810
Eksik etiket: 0, fazla etiket: 0
Etiketler kontrol ediliyor: 100% ██████████ 31240/31240 [00:01<00:00, 27261.66it/s]
Boş etiket: 0
Hatalı satır: 0

📊 Sınıf dağılımı (train):
cars (ID 0): 20548 (%34.8)
motorcycle (ID 1): 17125 (%29.0)
bus (ID 2): 11170 (%18.9)
truck (ID 3): 10205 (%17.3)


⚠ Bbox alan: min=0.000117, max=0.9993, ort=0.2074
%1'den küçük: 12546 (%21.2)
Görüntü kontrolü: 100% ██████████ 500/500 [00:00<00:00, 1883.39it/s]Bozuk/bulunamayan görüntü: 0

✓ Kontrol tamamlandı. Eğitime geçilebilir.

3. Özel YOLO Modelinin Eğitimi ve Mimarisi

Proje kapsamında nesne tespiti için YOLO11s (Small) mimarisi taban alınarak özel bir model (best.pt) eğitilmiştir.

- Mimari Detayları:** Model 182 katman, 9.429.340 parametre ve 21.7 GFLOPs işlem hacmine sahiptir. Bu yapı, hız ve doğruluk arasındaki optimum dengeyi sağlamaktadır.
- Donanım ve Süre:** Eğitim işlemi Tesla T4 GPU üzerinde 16 batch size ile gerçekleştirilmiş olup, toplam 12 epoch sürmüştür ve 2.399 saatte tamamlanmıştır.
- Optimizasyon:** Eğitimde AdamW optimizyer kullanılmış, lr0=0.0008 öğrenme oranı ve momentum=0.937 parametreleri ile ağırlıklar güncellenmiştir.



```

...
Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
6/12 6.96G 0.936 1.615 1.298 46 640: 100% 1953/1953 3.0it/s 10:48
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.3it/s 1:15
all 7810 15033 0.854 0.775 0.873 0.72

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
7/12 6.96G 0.8979 1.517 1.274 31 640: 100% 1953/1953 3.0it/s 10:48
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.2it/s 1:16
all 7810 15033 0.861 0.793 0.886 0.737

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
8/12 6.96G 0.8619 1.43 1.247 29 640: 100% 1953/1953 3.0it/s 10:46
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.3it/s 1:14
all 7810 15033 0.87 0.812 0.9 0.756

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
9/12 6.96G 0.8242 1.347 1.225 25 640: 100% 1953/1953 3.1it/s 10:38
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.3it/s 1:15
all 7810 15033 0.874 0.821 0.906 0.775

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
10/12 6.96G 0.7941 1.275 1.203 33 640: 100% 1953/1953 3.1it/s 10:38
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.3it/s 1:14
all 7810 15033 0.877 0.832 0.913 0.788

Closing dataloader mosaic
albumentations: Blur(p=0.01, blur_limit=(3, 7)), MedianBlur(p=0.01, blur_limit=(3, 7)), ToGray(p=0.01, method='weighted_average', num_output_channels=3), CLAHE(p=0

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
11/12 6.96G 0.6241 0.8879 1.08 19 640: 100% 1953/1953 3.3it/s 9:48
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.2it/s 1:17
all 7810 15033 0.882 0.833 0.918 0.789

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
12/12 6.96G 0.5967 0.8342 1.064 13 640: 100% 1953/1953 3.3it/s 9:43
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.3it/s 1:14
all 7810 15033 0.89 0.829 0.921 0.794

12 epochs completed in 2.399 hours.
Optimizer stripped from /content/drive/MyDrive/VehicleTraining_X/x_model/weights/last.pt, 19.2MB
Optimizer stripped from /content/drive/MyDrive/VehicleTraining_X/x_model/weights/best.pt, 19.2MB

Validating /content/drive/MyDrive/VehicleTraining_X/x_model/weights/best.pt...

```

```

Untitled0.ipynb ☆
Dosya Düzenle Göster Ekle Çalışma zamanı Araçlar Yardım

K Komutlar + Kod + Metin ▶ Tümünü çalıştır

9/12 6.96G 0.8242 1.347 1.225 25 640: 100% 1953/1953 3.1it/s 10:38
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.3it/s 1:15
all 7810 15033 0.874 0.821 0.906 0.775

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
10/12 6.96G 0.7941 1.275 1.203 33 640: 100% 1953/1953 3.1it/s 10:38
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.3it/s 1:14
all 7810 15033 0.877 0.832 0.913 0.788

Closing dataloader mosaic
albumentations: Blur(p=0.01, blur_limit=(3, 7)), MedianBlur(p=0.01, blur_limit=(3, 7)), ToGray(p=0.01, method='weighted_average', num_output_channels=3), CLAHE(p=0.01, clip_limit=(1.0, 4.0), t:

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
11/12 6.96G 0.6241 0.8879 1.08 19 640: 100% 1953/1953 3.3it/s 9:48
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.2it/s 1:17
all 7810 15033 0.882 0.833 0.918 0.789

Epoch GPU_mem box_loss cls_loss dfl_loss Instances Size
12/12 6.96G 0.5967 0.8342 1.064 13 640: 100% 1953/1953 3.3it/s 9:43
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.3it/s 1:14
all 7810 15033 0.89 0.829 0.921 0.794

12 epochs completed in 2.399 hours.
Optimizer stripped from /content/drive/MyDrive/VehicleTraining_X/x_model/weights/last.pt, 19.2MB
Optimizer stripped from /content/drive/MyDrive/VehicleTraining_X/x_model/weights/best.pt, 19.2MB

Validating /content/drive/MyDrive/VehicleTraining_X/x_model/weights/best.pt...
Ultralytics 8.4.117 Python-3.12.13 torch-2.11.0+cu128 CUDA:0 (Tesla T4, 14913MiB)
YOLO11s summary (fused): 101 layers, 9,414,348 parameters, 0 gradients, 21.4 GFLOPs
Class Images Instances Box(P R mAP50 mAP50-95): 100% 245/245 3.0it/s 1:21
all 7810 15033 0.891 0.829 0.921 0.793
cars 2061 5419 0.87 0.8 0.892 0.769
motorcycle 2182 4283 0.9 0.785 0.904 0.703
bus 1840 2818 0.914 0.855 0.945 0.854
truck 1727 2513 0.88 0.876 0.942 0.848

Speed: 0.2ms preprocess, 4.3ms inference, 0.0ms loss, 1.6ms postprocess per image
Results saved to /content/drive/MyDrive/VehicleTraining_X/x_model
Model Drive'a kaydedildi: /content/drive/MyDrive/best_araba_otobus_karismaz.pt

```

4. Model Başarımı ve Metrik Değerlendirmeleri

Eğitim sürecinden elde edilen results.csv kayıtları, PR (Precision-Recall) ve F1 eğrileri incelendiğinde modelin çok yüksek bir genelleme kapasitesine ulaştığı görülmektedir. Tüm sınıflar bazında elde edilen ortalama başarı oranları şu şekildedir:



- Precision (Kesinlik): %89.1
- Recall (Duyarlılık): %82.9
- mAP@0.50 (Ortalama Hassasiyet): %92.1

Sınıf Bazlı mAP@0.50 Performansları:

- Otobüs (Bus): %94.5 (En yüksek başarıml)
- Kamyon (Truck): %94.2
- Motosiklet (Motorcycle): %90.4
- Araba (Cars): %89.2

4.1. Eğitim Kayıpları (Loss) ve Eğri (Curve) Analizleri



- **Kayıp Eğrileri (results.csv):** Eğitim süreci boyunca train/box_loss ve val/box_loss değerlerinin birbirine paralel ve istikrarlı bir şekilde düşmesi, modelin veriyi ezberlemediğini (overfitting yapmadığını) kanıtlamaktadır. 12. epoch sonunda model maksimum performans noktasına ulaşmıştır.
- **PR Eğrisi (Precision-Recall Curve):** Tüm sınıflar için eğrinin grafiğın sağ üst köşesine oldukça yakınsaması (alanın büyük olması), modelin hem nesneleri kaçırmadan bulabildiğini (yüksek recall) hem de bulduklarının doğruluğundan emin olduğunu (yüksek precision) bilimsel olarak doğrulamaktadır.
- **F1-Confidence Eğrisi:** Model, 0.442 güven skorunda (confidence threshold) **0.86 F1 skoruna** ulaşmıştır. Bu veri, algoritmada tespit eşiğinin (conf_thresh) hangi seviyede tutulması gerektiği konusunda matematiksel bir dayanak sunmaktadır.



4.1. Sınıflandırma Hataları ve "Kaçırılan Araç" Analizi (Confusion Matrix)

Modelin hata toleransını analiz etmek için Normalize Edilmiş Karmaşıklık Matrisi (Confusion Matrix) incelenmiştir. Araba (cars) sınıfı için Doğru Pozitif (True Positive) oranı **%87**'dir.


Model, kare içindeki arabaların **%13'ünü arka plan (background) olarak algılamakta**, yani o anlık karede kaçırmaktadır. Ancak bu %13'lük anlık çerçeve (frame) kaybı, sistem mimarisindeki güçlü Takip (Tracking) algoritmaları sayesinde tolere edilmektedir.



5. Nesne Takibi (Object Tracking) ve Hata Tolerans Mimarisi

Modelin kare bazlı %13'lük anlık araç kaçırma ihtimaline karşı sistem, hataları yutması (hata toleransı) için güçlü dinamik takipçilerle güçlendirilmiştir. Bu yapı sayesinde "Kare Bazlı" kaçırılmalar, "**Video Bazlı**" (Sistem Genel Başarısı) kaçırılmalara dönüşmemektedir.

- **Yapay Zeka Tabanlı (ByteTrack & DeepSORT):** Nesnelerin sınır kutusu özelliklerini (IoU) ve görsel özniteliklerini (Re-ID) hesaplayarak hareket kinematiği çıkarır.
- **Centroid Tracker ve Geleneksel Takipçiler:** Merkez noktası tabanlı çalışan bu sistem, projede max_disappeared=50 parametresi ile konfigüre edilmiştir. Model bir aracı arka arkaya 50 kare boyunca tespit edemese (kaçırsaydı) bile, LK veya Centroid eşleştirmesi aracı hafızasında tutmakta ve geçiş çizgisinde (Zone End) sayım işlemi mükerrrer olmadan, kusursuzca yapılmaktadır.



6. Konum Eşleştirme ve Mesafe Metrikleri

Araçların kareler arası hareketlerini doğrulayabilmek için üç farklı matematiksel mesafe ölçüm metriği algoritmaya gömülmüştür:

- **Öklid (Euclidean) Mesafesi:** Kuş uçuşu doğrusal mesafeyi hesaplar. $d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$
- **Manhattan Mesafesi:** Izgara (grid) tabanlı, eksenlere paralel hareket mesafesini hesaplar. $d = |x_2 - x_1| + |y_2 - y_1|$

- **Chebyshev Mesafesi:** İki koordinat arasındaki maksimum mutlak eksen farkını temel alır. $d = \max(|x_2 - x_1|, |y_2 - y_1|)$



7. Veri Analitiği, Otonom Sınıflandırma ve Isı Haritası



Geliştirilen web arayüzü yalnızca tespit yapmamakta, veriyi işleyerek kalıcı çıktılara dönüştürmektedir:



1. **Otonom Veri Kırpma:** Tespit edilen araçlar bounding box koordinatlarına göre kırılarak, sınıf isimlerine göre (Örn: frame_12_id_5_blue.jpg) otonom olarak klasörlenmektedir.
2. **Isı Haritası (Heatmap):** Tespit edilen araçların koordinat pikselleri zaman içinde biriktirilerek (TrafficHeatmap sınıfı), yol üzerinde en yoğun kullanılan yörüngeler canlı kamera akışı üzerine termal bir katman olarak giydirilmektedir.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	epoch	time	train/box_loss	train/cls_loss	train/dfl_loss	metrics/precision(B)	metrics/recall(B)	metrics/mAP50(B)	metrics/mAP50-95(B)	val/box_loss	val/cls_loss	val/dfl_loss	lrpg0	lrpg1	lrpg2
2	1	815.706	1.16857	2.23439	1.45907	0.72018	0.58079	0.66459	0.47652	1.07042	2.14226	1.3645	0.00026653	0.00026653	0.0669503
3	2	1546.07	1.1432	2.18509	1.45301	0.7157	0.65176	0.72328	0.52187	1.02051	1.80558	1.31509	0.000524204	0.000524204	0.0338746
4	3	2270.4	1.09186	2.04468	1.4154	0.82881	0.71301	0.81005	0.59784	0.97645	1.44069	1.26657	0.000746819	0.000746819	0.000763886
5	4	2987.79	1.03942	1.90117	1.37855	0.81835	0.70962	0.81896	0.64606	0.80344	1.37073	1.18269	0.000684014	0.000684014	0.000684014
6	5	3705.83	0.9822	1.73705	1.3349	0.83979	0.75936	0.8605	0.6823	0.7914	1.20821	1.13808	0.000602	0.000602	0.000602
7	6	4430.53	0.93603	1.61545	1.29832	0.85423	0.77455	0.87341	0.72046	0.67839	1.1208	1.07066	0.000506492	0.000506492	0.000506492
8	7	5156.35	0.89793	1.51735	1.27371	0.86149	0.79342	0.88567	0.73723	0.66355	1.06579	1.06557	0.000404	0.000404	0.000404
9	8	5879.54	0.86188	1.43038	1.24724	0.87045	0.81182	0.89995	0.75552	0.63441	0.97433	1.03255	0.000301508	0.000301508	0.000301508
10	9	6593.74	0.82421	1.34668	1.22516	0.87375	0.82138	0.90649	0.7752	0.58937	0.91905	1.00316	0.000206	0.000206	0.000206
11	10	7307.11	0.79408	1.27484	1.20269	0.87734	0.83228	0.91345	0.78771	0.56746	0.86579	0.9926	0.000123986	0.000123986	0.000123986
12	11	7975.39	0.62411	0.88793	1.08049	0.88163	0.83307	0.91769	0.78905	0.57649	0.84251	0.98586	6.11E-05	6.11E-05	6.11E-05
13	12	8634.4	0.59666	0.83423	1.06408	0.89021	0.82947	0.92074	0.79388	0.5697	0.83332	0.98058	2.15E-05	2.15E-05	2.15E-05

8. Gerçek Zamanlı Sınıf Kararlılığı (Class Stability) ve Tracker Performans Analizi







Otonom trafik analiz sistemlerinde kameranın perspektifi, ışık yansımaları veya araçların birbirini kapatması (occlusion) nedeniyle derin öğrenme modelinin aynı aracı farklı karelerde farklı sınıflarda tahmin etmesi (*Flicker Effect*) sık karşılaşılan bir sorundur. Sistemin bu kararsızlığı ne ölçüde tolere edebildiğini bilimsel olarak ölçmek amacıyla "**Dinamik Sınıf Kararlılığı**" algoritması tasarlanarak sisteme entegre edilmiştir.

Sayım çizgisine yaklaşan her araç için son 10 karelik tahmin geçmişi tutulmaktadır. Model, bu karelerin en az %70'inde aynı sınıfı tahmin etmişse eşleşme "Başarılı/Kararlı", bu oranın altında kalmışsa "Kararsız" loglanmaktadır. Eğitilen özel model (**YOLO_CUSTOM**) ve **CHEBYSHEV** mesafe metriği sabit tutularak, 3 dakikalık yoğun trafik akışı içeren video kesiti üzerinde farklı takip algoritmaları koşturulmuş ve sonuçlar tabloya aktarılmıştır:

Tablo: Farklı Takip Algoritmaları ile Sınıf Kararlılığı ve Sayım Performansı (3 Dakikalık Test)

Dedektör Modeli	Takip Algoritması	Toplam Geçen Araç	Başarılı Eşleşme (> %70)	Kararsız Eşleşme (< %70)	Sistem Kararlılık Başarısı	Ortalama Hız (FPS)
YOLO_CUSTOM	LK (Optical Flow)	54	50	4	%92.6	~13.80
YOLO_CUSTOM	MOSSE	52	50	2	%96.2	~13.50
YOLO_CUSTOM	CSRT	51	47	4	%92.2	~13.40
YOLO_CUSTOM	KCF	50	44	6	%88.0	~12.60
YOLO_CUSTOM	ByteTrack	26	24	2	%92.3	~14.60

Dedektör Modeli	Takip Algoritması	Toplam Geçen Araç	Başarılı Eşleşme (> %70)	Kararsız Eşleşme (< %70)	Sistem Kararlılık Başarısı	Ortalama Hız (FPS)
YOLO_CUSTOM	DeepSORT	8	8	0	%?	~14.30

8.1. Deneysel Sonuçların Yorumlanması ve Algoritma Zayıflıkları

Elde edilen sonuçlar, yüksek kararlılık yüzdesinin tek başına yanıltıcı olabileceğini ve **toplam sayılan araç (Recall)** verisiyle değerlendirilmesi gerektiğini göstermektedir:

- **Optik Akışın (LK) Açık Üstünlüğü:** Lucas-Kanade (LK) algoritması, 3 dakikada 54 araç sayarak ekrandaki trafiği en kayıpsız okuyan tracker olmuştur. Model, piksellerdeki ışık yoğunluğunu takip ettiği için YOLO modeli bir anlığına aracı kaçırrsa bile LK aracı bırakmamış ve sayım çizgisine ulaştırmıştır. %92.6'lık kararlılığı ile gerçek saha şartlarına en uygun yöntemdir.
- **MOSSE Algoritmasının Dengesi:** Toplam 52 aracı saymayı başaran MOSSE, %96.2 gibi çok yüksek bir sınıf kararlılığı sunarak optik akışa en güçlü ve performanslı alternatif olduğunu kanıtlamıştır.
- **AI Tabanlı Takipçilerin (DeepSORT ve ByteTrack) Çöküşü:** DeepSORT algoritması %100 kararlılık göstermesine rağmen, 3 dakika içinde yalnızca 8 aracı sayabilmiştir. Araçları "okuyamamış" veya kimliklerini erken düşürmüştür. Benzer şekilde ByteTrack yalnızca 26 aracı (trafiğin yarısından azını) sayabilmiştir. ByteTrack'ın sadece sınır kutusu (Bounding Box) kesişimlerine güvenmesi, bu spesifik kamera açısındaki perspektif değişimlerine uyum sağlayamamasına ve sistemde körlüklere yol açmasına neden olmuştur.

8.2. Veri Seti Bütünlüğü (Dataset Integrity) ve Başarıya Etkisi

Sistemin sahada gösterdiği yüksek kararlılığın temelinde, kullanılan veri setinin kalitesi ve derinlemesine uygulanan ön işleme (pre-processing) adımları yatmaktadır. Modelin eğitimi öncesinde gerçekleştirilen otonom veri seti kontrolleri aşağıdaki istatistiksel bulguları ortaya koymuştur:

- **Sıfır Hata Toleransı:** Toplam 39.050 görüntünün (31.240 Train, 7.810 Val) tamamı işlenmiş olup; **0 eksik etiket, 0 boş etiket ve 0 bozuk/bulunamayan görüntü** tespit edilmiştir. Veri setinin yapısal kusursuzluğu, modelin eğitim esnasında gürültülü (noisy) verilerden etkilenmesini tamamen engellemiştir.
- **Gerçekçi Sınıf Dağılımı:** Eğitim verilerindeki etiketlerin **%34.8'i Araba (20.548), %29.0'ı Motosiklet (17.125), %18.9'u Otobüs (11.170) ve %17.3'ü Kamyon (10.205)** olarak ölçülmüştür. Bu asimetrik ama dengeli yapı, günlük hayattaki gerçek trafik dağılımını birebir simüle etmekte; modelin ağır vasıtalar ile küçük binek araçları ayırt etme yeteneğini maksimize etmektedir.
- **Sınır Kutusu (Bounding Box) Analitiği ve Uzak Mesafe Tespiti:** Veri setindeki sınır kutularının ortalama alanı **0.2074** (görüntünün beşte biri) olup, etiketlerin **%21.2'sinin (12.546 adet)** görüntünün %1'inden daha küçük olduğu analiz edilmiştir.
- **Sonuç ve Analiz Yorumu:** Veri setindeki bounding box'ların %21.2'sinin mikroskobik boyutlarda (%1'den küçük) olması, modelin **çok uzak mesafedeki araçları bile henüz kadrja yeni girdiklerinde tanıyabilecek şekilde eğitildiğini** kanıtlamaktadır. Modelin mAP@0.50 skorunun **%92.1** gibi rekabetçi bir seviyeye ulaşmasının ana nedeni; eksiksiz, temiz ve uzak mesafe tespitine imkan tanıyan bu yüksek kaliteli veri seti mühendisliğidir. Bu teorik başarı, sahadaki LK (Optical Flow) performansı ile birleştğinde sistemin hem anlık tespit hem de süreklilikte endüstri standartlarını karşıladığını doğrulamaktadır.

9. Sonu

Geliřtirilen bu otonom panel, standart genel maksatlı modeller yerine dođrudan hedef senaryoya uygun zelleřtirilmiř veri seti ile eđitilmiř gl bir model barındırmaktadır. Test bulguları, modelin kare bazlı zayıflıklarının (%13'lk kayıp oranı) entegre edilen eřleřtirme algoritmalarıyla tamamen kapatıldığını kanıtlamıřtır. zellikle **YOLO zel Model + LK (Optical Flow)** veya **MOSSE** kombinasyonlarının, gerek zamanlı sayım dođruluđu ve kimlik koruma kapasitesi aısından en stabil mimari olduđu saha testleriyle dođrulanmıřtır. Dinamik model ve tracker deđiřimi, otonom kırpma ve sınıf kararlılıđı algoritması zellikleriyle proje, akademik ve endstriyel beklentileri karřılayan utan uca eksiksiz bir rn halini almıřtır.